

论文深度解读报告

论文基本信息提取

这篇论文介绍了扩散概率模型（Denoising Diffusion Probabilistic Models），以下是对论文基本信息和内容的深入分析：

1. 论文基本信息

- 标题：Denoising Diffusion Probabilistic Models
- 作者：未提供
- 发表年份：2020
- 期刊/会议：NeurIPS 2020

2. 论文内容分析

本文主要介绍了扩散概率模型，该模型是一种基于马尔可夫链的生成模型，通过逐步添加噪声和逐步去除噪声的过程来生成高质量样本。

(1) 扩散过程与去噪过程

- 扩散过程：逐步添加高斯噪声到数据上，直至信号被破坏。
- 去噪过程：逐步去除噪声，恢复原始数据。

(2) 模型结构

- 前向过程：从原始数据开始，逐步添加噪声，得到一个马尔可夫链。
- 反向过程：从去噪后的数据开始，逐步去除噪声，恢复原始数据。

(3) 训练过程

- 使用变分推断来训练模型，优化负对数似然。
- 使用KL散度来比较前向过程后验和反向过程。

(4) 模型参数

- 前向过程方差：可以是常数，也可以是可学习的。
- 反向过程参数：包括均值和协方差。

(5) 模型应用

- 生成高质量样本，在图像和音频等领域具有广泛应用前景。
- 与去噪分数匹配和退火朗之万动力学有联系。

3. 公式解读

- 公式(1): 定义了扩散过程，其中 $x_{t-1} | x_t$ 表示在t时刻，给定 x_t 的情况下， x_{t-1} 的概率分布。
- 公式(2): 定义了去噪过程，其中 $x_t | x_{t-1}$ 表示在t时刻，给定 x_{t-1} 的情况下， x_t 的概率分布。
- 公式(3): 定义了变分推断的目标函数，即负对数似然。
- 公式(4): 给出了去噪过程的采样公式，其中 x_t 表示在t时刻的样本， x_0 表示原始数据。
- 公式(5): 定义了变分推断的目标函数，即KL散度。

- 公式(6): 给出了去噪过程后验的采样公式, 其中 x_{t-1} 表示在 t 时刻, 给定 x_t 和 x_0 的情况下, x_{t-1} 的样本。
- 公式(7): 给出了去噪过程后验的均值和协方差。
- 公式(8): 定义了反向过程的损失函数, 其中 $\tilde{\mu}_t$ 表示前向过程后验的均值。
- 公式(9): 给出了反向过程损失函数的另一种表达形式。
- 公式(10): 给出了反向过程损失函数的另一种表达形式。
- 公式(11): 给出了反向过程参数的另一种表达形式。
- 公式(12): 给出了反向过程损失函数的另一种表达形式。
- 公式(13): 定义了去噪过程的解码器, 其中 x_{i0} 表示数据在 i 维的坐标。

4. 总结

本文介绍了扩散概率模型, 该模型通过逐步添加和去除噪声来生成高质量样本。论文详细分析了模型结构、训练过程和参数, 并展示了模型在图像和音频领域的应用。此外, 论文还探讨了模型与去噪分数匹配、退火朗之万动力学等方法之间的联系。

摘要解读与扩展

解读摘要内容

这篇论文的主要贡献在于以下几个方面:

1. 扩散概率模型在图像合成中的应用:

- 论文提出了一个基于扩散模型的图像合成方法, 该方法通过在潜在空间中逐步添加噪声, 然后逐步去除噪声来生成图像。
- 论文通过引入去噪分数匹配和Langevin动力学, 提高了图像合成的质量和效率。

2. 与去噪分数匹配和Langevin动力学的联系:

- 论文将扩散模型与去噪分数匹配和Langevin动力学联系起来, 通过优化去噪分数匹配的目标函数, 实现了对扩散模型的训练。
- 论文通过引入Langevin动力学, 提高了图像合成的采样效率。

扩展摘要内容

1. 扩散模型在图像合成中的潜在应用:

- 扩散模型可以应用于图像编辑、图像修复、图像超分辨率等领域。
- 扩散模型可以与其他生成模型结合, 进一步提高图像合成的质量和效率。

2. 扩散模型在其他数据模态和机器学习系统中的潜在用途:

- 扩散模型可以应用于音频、视频、文本等数据模态的生成和编辑。
- 扩散模型可以应用于强化学习、无监督学习等领域。

公式解读

1. 公式 (8):

$$L_{t-1} = E_{x_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(x_0, x_0) - \mu_\theta(x_t, t)\|^2 + C \right]$$

- 该公式描述了扩散模型中Langevin动力学的前向过程。

- 其中, L_{t-1} 表示前向过程在时间 $t - 1$ 的Langevin动力学, σ_t^2 表示噪声方差, $\tilde{\mu}_t(x_0, x_0)$ 表示前向过程的后验均值, $\mu_\theta(x_t, t)$ 表示模型预测的后验均值, C 是一个常数。

2. 公式 (10):

$$L_{t-1} - C = E_{x_0, \epsilon} \left[\frac{1}{2\sigma_t^2} \left(\frac{1}{\sqrt{\alpha_t}} (x_t(x_0, \epsilon) - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)) - \mu_\theta(x_t(x_0, \epsilon), t) \right)^2 \right]$$

- 该公式描述了扩散模型中Langevin动力学的反向过程。
- 其中, L_{t-1} 表示反向过程在时间 $t - 1$ 的Langevin动力学, σ_t^2 表示噪声方差, $x_t(x_0, \epsilon)$ 表示前向过程生成的样本, $\epsilon_\theta(x_t, t)$ 表示模型预测的噪声, $\mu_\theta(x_t(x_0, \epsilon), t)$ 表示模型预测的后验均值。

3. 公式 (11):

$$\mu_\theta(x_t, t) = \tilde{\mu}_t(x_t, \frac{1}{\sqrt{\alpha_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)))$$

- 该公式描述了模型预测的后验均值。
- 其中, $\mu_\theta(x_t, t)$ 表示模型预测的后验均值, $\tilde{\mu}_t(x_t, \frac{1}{\sqrt{\alpha_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_\theta(x_t, t)))$ 表示模型预测的前向过程的后验均值。

4. 公式 (14):

$$L_{simple}(\theta) = E_{x_0, \epsilon} [\|\epsilon - \epsilon_\theta(\sqrt{\alpha_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)\|^2]$$

- 该公式描述了简化后的训练目标函数。
- 其中, $L_{simple}(\theta)$ 表示简化后的训练目标函数, ϵ 表示噪声, $\epsilon_\theta(\sqrt{\alpha_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)$ 表示模型预测的噪声。

研究背景与意义分析

研究背景分析:

论文的研究背景主要集中在深度生成模型的发展, 特别是关注了GANs (生成对抗网络)、自回归模型、流模型和变分自编码器等。这些模型在图像合成、数据压缩和表示学习等领域都取得了显著的进展。其中, 扩散模型作为一种新兴的深度生成模型, 因其独特的噪声添加过程和潜在变量的表示能力, 在图像合成等领域展现出巨大的潜力。

具体来说, 扩散模型通过将数据点逐渐添加高斯噪声, 将其从原始数据分布转移到噪声分布, 然后通过学习一个逆过程来从噪声分布中恢复出原始数据。这种模型的优势在于, 它能够有效地捕捉数据的潜在结构, 并生成高质量的合成图像。

研究意义分析:

论文探讨了扩散模型在图像合成中的优势, 以及其在数据压缩和表示学习中的潜在应用。

- 图像合成: 扩散模型能够生成高质量的合成图像, 尤其是在处理复杂场景和细节丰富的图像时。论文中提到的公式 (1) 和 (2) 分别描述了扩散模型的前向过程和逆过程, 它们通过逐步添加和去除噪声来实现图像的生成和恢复。
- 数据压缩: 扩散模型可以用于数据压缩, 通过将数据转换为潜在空间, 并去除冗余信息, 从而实现数据的压缩。论文中提到的公式 (3) 描述了训练过程中优化的目标函数, 它通过最小化负对数似然来学习模型的参数。
- 表示学习: 扩散模型可以用于学习数据的潜在表示, 从而更好地理解数据的结构和模式。论文中提到的公式 (4) 和 (5) 分别描述了扩散模型中采样和优化的过程, 它们通过学习潜在空间的分布来实现表示学习。

总结:

这篇论文的研究背景和意义分析表明, 扩散模型作为一种新兴的深度生成模型, 在图像合成、数据压缩和表示学习等领域具有巨大的潜力。论文通过深入分析扩散模型的理论基础和实际应用, 为该领域的研究提供了新的思路和方法。

研究方法详解

以下是对论文中研究方法的深入分析：

解读扩散模型

论文详细解读了扩散模型的概念，包括前向过程、后向过程和变分推断。扩散模型通过逐步向数据中添加噪声，将数据从真实分布转换到高斯分布，从而实现数据的去噪和生成。

前向过程：逐步向数据中添加噪声，将数据从真实分布转换到高斯分布。论文中，前向过程的方差 β_t 被固定为常数，从而简化了模型。

后向过程：逐步去除噪声，将数据从高斯分布恢复到真实分布。论文中，后向过程使用神经网络进行建模，并使用变分推断进行训练。

变分推断：使用变分推断来估计后验分布，从而实现数据的生成和去噪。论文中，使用KL散度作为变分下界，并提出了简化的加权变分边界目标函数。

解读去噪分数匹配

论文分析了去噪分数匹配在扩散模型中的应用，并将其与Langevin动力学联系起来。

去噪分数匹配是一种基于KL散度的目标函数，用于衡量数据分布与模型生成分布之间的差异。论文中，将去噪分数匹配应用于扩散模型的后向过程，并将其与Langevin动力学联系起来，从而实现了对数据的生成和去噪。

解读公式推导

论文再现和解读了论文中提出的公式，包括变分边界、KL散度和对数似然等。

变分边界：

$$L = D_{KL}(q(x_T|x_0) \parallel p(x_T)) + E_{x_0, \epsilon} \left[\sum_{t=1}^T D_{KL}(q(x_{t-1}|x_t) \parallel p_{\theta}(x_{t-1}|x_t)) \right] + H(x_0)$$

KL散度：

$$D_{KL}(p \parallel q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

对数似然：

$$\log p(x) = \log \frac{p(x)}{q(x)}$$

公式解读

公式 (8)：

$$L_{t-1} = E_{x_0, \epsilon} \left[\frac{1}{2} \sigma_t^2 \|\tilde{\mu}_t(x_t, x_0) - \mu_{\theta}(x_t, t)\|^2 \right] + C$$

该公式描述了后向过程的KL散度，其中 σ_t^2 是噪声方差， $\tilde{\mu}_t$ 是前向过程的后验均值， μ_{θ} 是后向过程的均值函数。

公式 (9)：

$$L_{t-1} - C = E_{x_0, \epsilon} \left[\frac{1}{2} \sigma_t^2 \left(\frac{\tilde{\mu}_t(x_t, x_0)}{\sqrt{\alpha_t}} - \mu_{\theta}(x_t, t) \right)^2 \right]$$

该公式将公式 (8) 进一步展开，并引入了前向过程的后验公式。

公式 (11):

$$\mu_{\theta}(x_t, t) = \tilde{\mu}_t(x_t, x_0) \frac{\sqrt{\bar{\alpha}_t}}{\sqrt{1 - \bar{\alpha}_t}} (x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_{\theta}(x_t, t))$$

该公式描述了后向过程的均值函数，其中 ϵ_{θ} 是一个函数逼近器，用于预测噪声。

公式 (12):

$$E_{x_0, \epsilon} \left[\frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)} (\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t))^2 \right]$$

该公式描述了去噪分数匹配的目标函数，其中 ϵ 是噪声， ϵ_{θ} 是函数逼近器。

公式 (14):

$$L_{simple}(\theta) = E_{x_0, \epsilon} \left[\frac{1}{2} (\epsilon - \epsilon_{\theta}(\sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t))^2 \right]$$

关键创新点识别与分析

识别创新点

1. 扩散模型与去噪分数匹配的结合:

- 论文中提出了一种新的显式联系，将扩散模型与去噪分数匹配 (Denoising Score Matching, DSM) 结合起来。这种结合允许使用DSM的目标函数来训练扩散模型，从而提高图像合成质量。

2. 渐进式有损压缩方案:

- 论文中提出了一种渐进式有损压缩方案，该方案通过逐步增加噪声水平来模拟图像的生成过程，从而实现高效的图像压缩和解压缩。

分析创新点

1. 扩散模型与去噪分数匹配的结合:

公式分析:

- $L_t = E_{q_{x_0, \epsilon}} \left[\frac{1}{2\sigma_t^2} \|\tilde{\mu}_t(x_0, \epsilon) - \mu_{\theta}(x_t, t)\|^2 + C \right]$
- 该公式描述了扩散模型中后向过程的损失函数，其中 $\tilde{\mu}_t$ 是前向过程的后验均值， μ_{θ} 是模型预测的后验均值， σ_t 是噪声标准差。

创新点分析:

- 通过将DSM的目标函数与扩散模型结合，论文提出了一种新的训练方法，该方法可以有效地提高图像合成质量。DSM通过最小化数据分布与去噪后数据分布之间的差异来训练模型，而扩散模型则通过逐步添加噪声来生成图像。这种结合使得模型能够更好地学习数据的潜在结构。

2. 渐进式有损压缩方案:

公式分析:

- $L = DKL(q(x_T) || p(x_T)) + E_{q_{t \geq 1}} DKL(q(x_{t-1} | x_t) || p_{\theta}(x_{t-1} | x_t)) + H(x_0)$
- 该公式描述了扩散模型的变分界限，其中 $q(x_T)$ 是前向过程的分布， $p(x_T)$ 是先验分布， $H(x_0)$ 是先验分布的熵。

创新点分析:

- 论文中提出的渐进式有损压缩方案通过逐步增加噪声水平来模拟图像的生成过程，从而实现高效的图像压缩和解压缩。这种方案可以有效地降低图像的比特率，同时保持较高的图像质量。此外，该方案还可以用于图像的渐进式生成，即逐步恢复图像的细节。

总结

论文中提出的创新点有效地提高了图像合成质量和图像压缩效率。通过结合扩散模型与去噪分数匹配，论文提出了一种新的训练方法，该方法可以有效地提高图像合成质量。此外，论文还提出了一种渐进式有损压缩方案，该方案可以有效地降低图像的比特率，同时保持较高的图像质量。这些创新点为图像处理和图像压缩领域提供了新的思路和方法。

实验设计与结果分析

分析实验设计

数据集：

- 论文中使用了多个数据集，包括CIFAR10和LSUN Church、Bedroom，用于评估模型在不同类型的图像上的表现。

模型架构：

- 模型采用了一个U-Net架构，类似于未掩码的PixelCNN++，并使用了组归一化。
- 网络参数在时间上共享，使用Transformer正弦位置编码指定时间。
- 在16x16特征图分辨率上使用自注意力。

评估指标：

- 使用了Inception分数、FID分数和负对数似然（无损码长）来评估样本质量。
- 使用了损失函数来评估模型的训练目标。

分析实验结果

样本质量：

- 在CIFAR10数据集上，模型的FID分数为3.17，优于大多数文献中的模型，包括类条件模型。
- 当使用训练集计算FID分数时，分数为5.24，仍然优于许多训练集FID分数。
- 在LSUN Church和Bedroom数据集上，FID分数分别为7.89和4.90，表明模型在这些数据集上也有很好的表现。

FID分数：

- FID分数是衡量生成图像与真实图像相似度的指标，数值越低表示越相似。
- 论文中模型的FID分数表明，生成的图像与真实图像非常相似。

NLL测试：

- NLL测试用于评估模型的生成质量，数值越低表示生成质量越好。
- 论文中模型在CIFAR10数据集上的NLL测试结果优于其他基于能量的模型和分数匹配使用退火重要性采样的模型。

反向过程参数化和训练目标消融：

- 研究了不同反向过程参数化和训练目标对样本质量的影响。
- 发现预测 μ 仅在训练在真实变分边界时表现良好，而预测 ϵ 在训练在简化目标时表现更好。

渐进编码：

- 研究了渐进编码对模型的影响，发现模型的损失率与测试集之间的差距最大为0.03位/维度，表明模型没有过拟合。
- 模型的无损码长优于其他类型的基于似然的生成模型。

渐进生成：

- 研究了渐进生成对模型的影响，发现大型图像特征首先出现，细节最后出现。

与自回归解码的联系：

- 将变分边界重新写为自回归解码的形式，表明Gaussian扩散模型可以看作是一种自回归模型。

插值：

- 使用反向过程进行插值，可以生成高质量的重建和插值图像。

公式解读

- 变分边界：** $L = D_{KL}(q(x_T)||p(x_T)) + E_{t=1}^T D_{KL}(q(x_{t-1}|x_t)||p_{\theta}(x_{t-1}|x_t)) + H(x_0)$
- 渐进生成：** $x_0 \approx \hat{x}_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \epsilon_{\theta}(x_t)}{\sqrt{\bar{\alpha}_t}}$
- 插值：** $\hat{x}_0 = (1 - \lambda)x_0 + \lambda x'_0$

这些公式揭示了模型的内部机制和性能表现，为理解和改进模型提供了重要信息。

结论与贡献总结

总结结论分析：

论文的主要结论集中在扩散模型在图像合成中的有效性，以及其与其他生成模型的关联。以下是对结论的详细分析：

- 扩散模型的有效性：** 论文指出，通过扩散模型可以生成高质量的图像样本，这表明扩散模型在图像合成任务中具有强大的能力。扩散模型通过将数据从简单分布（如高斯分布）扩散到复杂分布（如真实图像分布）来学习数据的潜在结构。
- 与其他生成模型的比较：** 论文提到了扩散模型与多种生成模型的联系，包括变分推理、去噪评分匹配、退火拉格朗日动力学（以及基于能量的模型）、自回归模型和渐进式有损压缩。这表明扩散模型不仅是一个独立的生成模型，而且可以与其他技术结合，以增强其性能。
- 潜在应用：** 论文提到，扩散模型可能在其他数据模态和生成模型中发挥作用，这表明其应用范围可能远远超出图像合成。

总结贡献分析：

论文的主要贡献包括对扩散模型的理解和改进，以及其在图像合成和数据压缩中的应用：

- 对扩散模型的理解和改进：** 论文可能通过理论分析和实验验证，对扩散模型的工作原理进行了深入探讨，并可能提出了改进方法，如新的训练策略或模型结构。
- 图像合成中的应用：** 论文可能通过实验展示了扩散模型在生成高质量图像方面的能力，这可能包括新的图像生成算法或对现有算法的改进。
- 数据压缩中的应用：** 论文可能探讨了扩散模型在数据压缩方面的潜力，这可能涉及到如何利用扩散模型来减少数据的大小，同时保持数据的可接受质量。

公式解读：

由于论文中没有直接给出具体的公式，以下是一些可能涉及到的公式及其在LATEX格式中的表示：

- **扩散过程**：扩散过程可以用以下公式表示：

$$p(x_t|x_{t-1}) = \mathcal{N}(x_t; \mu(x_{t-1}), \Sigma(x_{t-1}))$$

其中， x_t 是在时间 t 的数据点， $\mu(x_{t-1})$ 和 $\Sigma(x_{t-1})$ 分别是均值和协方差矩阵，表示数据点在时间 $t - 1$ 的分布。

- **去噪评分匹配**：去噪评分匹配可以用以下公式表示：

$$\min_{\theta} \mathbb{E}_{x \sim p_{data}} [D_{KL}(p_{noise}(x) || p_{data}(x))]$$

其中， D_{KL} 表示KL散度， p_{data} 是数据分布， p_{noise} 是噪声分布。

- **退火拉格朗日动力学**：退火拉格朗日动力学可以用以下公式表示：

$$\frac{d}{dt} x_t = -\nabla V(x_t) + \gamma(t) \nabla^2 V(x_t)$$

其中， x_t 是系统状态， $V(x_t)$ 是势能函数， $\gamma(t)$ 是随时间退火的参数。

这些公式展示了扩散模型、去噪评分匹配和退火拉格朗日动力学等概念在数学上的表达。

局限性与未来研究方向

分析局限性

1. 模型复杂度：

- 论文中提到的模型使用了U-Net架构和Transformer的位势嵌入，这些结构本身较为复杂，导致模型训练和推理的时间成本较高。
- 模型的训练时间可能较长，特别是在大规模数据集上，这限制了模型在实际应用中的效率。

2. 训练时间和对数据集的依赖性：

- 模型的训练时间与数据集的大小和复杂性密切相关。在论文中，作者使用了CIFAR10和LSUN数据集，这些数据集相对较小，但实际应用中可能需要处理更大的数据集，这将进一步增加训练时间。
- 模型对数据集的依赖性较强，这意味着模型的性能可能会随着数据集的不同而变化。

3. 逆过程参数化和训练目标：

- 论文中提到，预测误差 ϵ (ϵ) 比预测均值 μ ($\sim \mu$) 在简化目标下表现更好。这可能意味着模型对训练目标的敏感性较高，需要仔细调整以获得最佳性能。

提出未来研究方向

1. 改进模型效率：

- 研究更高效的模型结构，例如使用轻量级的神经网络架构，以减少模型复杂度和训练时间。
- 探索并行计算和分布式训练技术，以加快模型的训练和推理速度。

2. 扩展到其他数据模态：

- 将扩散模型应用于其他数据模态，如音频、视频和文本，以探索其在不同领域的应用潜力。
- 研究如何将扩散模型与现有的数据模态生成模型结合，以创建更强大的跨模态生成系统。

3. 与其他生成模型的结合：

- 探索将扩散模型与GANs、变分自编码器 (VAEs) 等生成模型结合，以利用各自的优势。
- 研究如何通过结合不同的生成模型来提高样本质量和多样性。

4. 模型稳定性和鲁棒性：

- 研究提高模型稳定性和鲁棒性的方法，以应对数据集的不完整性和噪声。
- 探索如何提高模型对对抗攻击的抵抗能力。

5. 数据压缩应用：

- 研究将扩散模型应用于数据压缩，以减少存储和传输成本。
- 探索如何利用扩散模型实现更高效的渐进式损失压缩。

通过解决上述局限性和探索新的研究方向，扩散模型有望在图像生成、数据压缩和其他领域取得更大的进展。

相关工作与文献综述分析

分析相关工作：

- 扩散模型**：论文中提到扩散模型与流模型（flows）和变分自编码器（VAEs）相似，但扩散模型设计时确保了先验分布 q 没有参数，并且最高层的潜在变量 x_T 与数据 x_0 之间的互信息几乎为零。这种设计使得扩散模型在去噪和生成任务中具有独特的优势。
- 去噪分数匹配**：论文中提到，通过 ϵ -预测反向过程参数化，建立了扩散模型与去噪分数匹配之间的联系。这种联系使得扩散模型能够通过变分推理来训练Langevin动力学采样器，从而实现高效的去噪和生成。
- Langevin动力学**：论文中提到，扩散模型与Langevin动力学有紧密的联系。通过 ϵ -预测参数化，扩散模型可以简化为类似于Langevin动力学的采样过程，从而提高了去噪和生成的效率。
- 自回归模型**：论文中提到，扩散模型可以看作是自回归模型的一种特殊形式。通过将自回归模型扩展到多尺度，扩散模型能够更好地捕捉数据的复杂结构。

综述文献：

- 能量基模型**：论文中提到，通过分数匹配与能量基模型之间的联系，扩散模型的研究可能对能量基模型的其他相关工作产生影响。
- 变分推理**：论文中提到，扩散模型与变分推理有紧密的联系。通过变分推理，扩散模型能够有效地学习数据的分布。
- 变分自编码器**：论文中提到，扩散模型与变分自编码器有相似之处，但扩散模型在去噪和生成任务中具有独特的优势。

公式分析：

- 公式 (8)**：该公式描述了Langevin动力学中，时间步长为 t 时的Langevin扩散过程的后验均值与先验均值之间的差异。
- 公式 (9)**：该公式通过重新参数化公式 (4)，进一步分析了Langevin扩散过程的后验均值。
- 公式 (10)**：该公式描述了 ϵ -预测参数化下的Langevin动力学采样过程。
- 公式 (11)**：该公式描述了 ϵ -预测参数化下的Langevin动力学采样过程中的均值函数。
- 公式 (12)**：该公式描述了 ϵ -预测参数化下的Langevin动力学采样过程中的方差。
- 公式 (14)**：该公式描述了简化后的变分边界目标函数，该函数强调了不同尺度的去噪任务。

通过以上分析，我们可以看出，该论文在扩散模型、去噪分数匹配、Langevin动力学和自回归模型等方面进行了深入研究，并提出了一种新的 ϵ -预测参数化方法，有效地提高了扩散模型的去噪和生成性能。